E S C U E L A P O L I T É C N I C A N A C I O N A L

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

I N F O R M E D E L A B O R A T O R I O · S E M A N A 3

Clasificación de variables y población vs. muestra

Laboratorio complementario · Semana 3 · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Campo	Dato
Estudiante(s)	Tingo Pérez Alan Fernando — usuario de GitHub: AlanTingo
Docente	Ing. Christian Suarez
Período académico	2026-B
Fecha de entrega	22/10/2026
Repositorio (fork)	https://github.com/AlanTingo/IDSD422-lab-muestreo-poblacion

1. Introducción

RetailAndina S.A. necesita conocer su base de fidelización antes de analizarla: qué variables contiene y qué análisis admite cada una. Además, la gerencia quiere estimar el ingreso mensual promedio de sus clientes a partir de muestras de 20 registros, con evidencia de que esas muestras representan a la población de 400 clientes. Como analista de Business Intelligence, clasifiqué las variables con un criterio explícito, verifiqué esa clasificación en código y comparé tres diseños de muestreo (conveniencia, aleatorio simple y estratificado) contra el parámetro poblacional.

Esto importa por dos razones. Una variable mal clasificada lleva a análisis inválidos: por ejemplo, tratar una escala ordinal como si fuera un número continuo, o dejar una categoría ordenada como texto sin declarar su orden. Y una muestra mal diseñada no se corrige con más filas: si el diseño está sesgado, un tamaño mayor solo repite el error con más datos.

2. Objetivos

Objetivo general: clasificar las variables de la base de fidelización y comparar tres diseños de muestreo contra el parámetro poblacional del ingreso mensual.

Objetivos específicos:

1. Clasificar las 7 variables (más el identificador) con el criterio y verificar su tipo en código.
2. Declarar el orden de las variables ordinales y comprobar que se aplicó.
3. Comparar conveniencia, aleatorio simple y estratificado contra el parámetro poblacional.
4. Interpretar el sesgo y la variabilidad de las estimaciones e informar sus límites.

3. Desarrollo de la práctica

3.1 Parte A · Clasificación de las variables

Hice un fork del repositorio del laboratorio en mi cuenta (AlanTingo), lo cloné en Google Colab con un token personal e instalé `pandas`. Trabajé en Python, sobre `data/clientes.csv` (12 clientes, 7 variables y el identificador), y subí un commit por cada script completado. **Problemas que tuve:** (1) Colab reinició la sesión y `cat scripts/muestreo.py` dio "No such file or directory"; volví a clonar el fork y comprobé con `git log` que mi commit de la Parte A seguía en GitHub. (2) Para la prueba del error de escritura, usé "Postgrado" (con t) en las categorías y comprobé que no se genera ningún aviso (ver P1).

Para clasificar cada variable usé tres preguntas: ¿tiene sentido la mitad del valor?, ¿hay orden entre las categorías? y, si es numérica, ¿se mide o se cuenta?

Variable	Tipo	Justificación (criterio)	Verificación en código
`cliente_id`	Identificador	Solo etiqueta a cada cliente; promediar o comparar identificadores no tiene sentido.	`object`; 12 únicos (C001 a C012). Se excluye del análisis.
`edad`	Cuantitativa continua	La mitad tiene sentido (44 años es el doble de 22). Se mide con el tiempo; que venga en años enteros es solo la forma de registrarla.	`int64`; 12 únicos (22 a 48).
`numero_hijos`	Cuantitativa discreta	La mitad tiene sentido y se cuenta: solo toma valores enteros; no existen 2,5 hijos.	`int64`; 5 únicos (0 a 4).
`genero`	Cualitativa nominal	Tres categorías sin orden entre sí y sin sentido numérico.	`object`; 3 únicos (Femenino, Masculino, Otro).
`nivel_educacion`	Cualitativa ordinal	Orden natural: Primaria < Secundaria < Universidad < Posgrado; la distancia entre niveles no es medible.	`object`; 4 únicos. Orden declarado con `CategoricalDtype`; `min()` = Primaria.
`ciudad`	Cualitativa nominal	Quito, Guayaquil y Cuenca son categorías sin orden.	`object`; 3 únicos.

Variable	Tipo	Justificación (criterio)	Verificación en código
`ingresos_mensuales`	Cuantitativa continua	La razón tiene sentido (2 000 es el doble de 1 000) y es una medida monetaria que admite valores intermedios, aunque venga en dólares enteros.	`int64`; 12 únicos (760 a 2 450).
`satisfaccion`	Cualitativa ordinal	Escala de opinión con orden, pero 4 no es el doble de 2 y no hay cero real.	`int64`; 4 únicos (2 a 5). Orden declarado en escala 1 a 5; `min()` = 2.

Discusión de edad: conceptualmente es continua, porque el tiempo transcurrido se mide y no se cuenta. En los datos llega como entero (`int64`) solo porque se registra en años cumplidos, y ese redondeo no cambia la naturaleza de la variable. Algunos textos tratan la edad en años enteros como discreta; yo la clasifiqué como continua por lo que mide, no por cómo se guarda.

Para declarar el orden de las ordinales y probar el error de escritura usé este código:

Python

```
orden_edu = ["Primaria", "Secundaria", "Universidad", "Posgrado"]
clientes["nivel_educacion"] = clientes["nivel_educacion"].astype(
    pd.CategoricalDtype(categories=orden_edu, ordered=True))     # min() -> Primaria
clientes["satisfaccion"] = clientes["satisfaccion"].astype(
    pd.CategoricalDtype(categories=[1, 2, 3, 4, 5], ordered=True))  # min() -> 2
# Prueba del typo: "Postgrado" (con t) en la lista de categorías
con_typo = clientes["nivel_educacion"].astype(str).astype(
    pd.CategoricalDtype(categories=["Primaria","Secundaria","Universidad","Postgrado"],
ordered=True))
print(con_typo.isna().sum())                                          # -> 2 faltantes
```



Figura 1. Exploración de clientes.csv: dtype y valores únicos por columna.

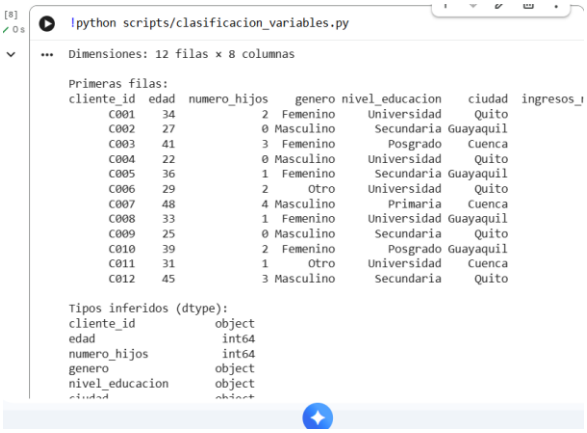


Figura 2. Ejecución de clasificacion_variables.py: dimensiones (12 × 8) y tipos inferidos.

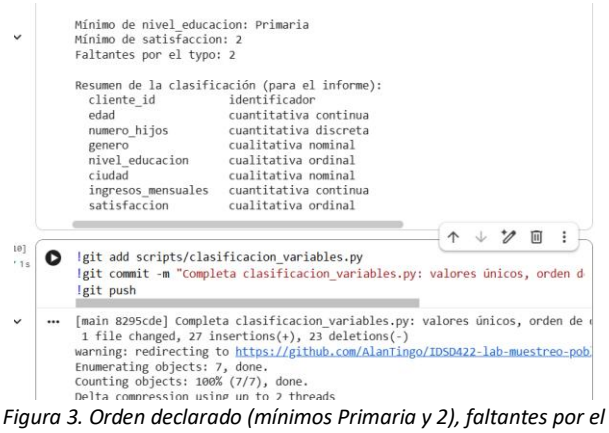


Figura 3. Orden declarado (mínimos Primaria y 2), faltantes por el typo (2), resumen de la clasificación y commit.

P1. ¿Qué dijo el dtype de satisfaccion y por qué no basta? Dijo `int64`: llegó como número, con valores de 2 a 5. Pero el dtype solo describe cómo se almacenó, no qué es la variable: 4 no es el doble de 2, así que es una escala ordinal y no una medida continua. Si una ordinal queda como texto sin orden, Python la ordena alfabéticamente: en mi salida `nivel_educacion` apareció como Posgrado, Primaria, Secundaria, Universidad, con Posgrado antes que Primaria. Declarar el orden lo corrigió (`min()` dio Primaria), y la prueba del typo mostró que un nombre mal escrito deja 2 faltantes (C003 y C010) sin ningún error.

3.2 Parte B · Población vs. muestra

La población es `data/clientes_400.csv` (400 clientes) y la variable de interés es `ingresos_mensuales`. Primero calculé el parámetro y luego corrí los tres diseños con n = 20 en `muestreo.py`.

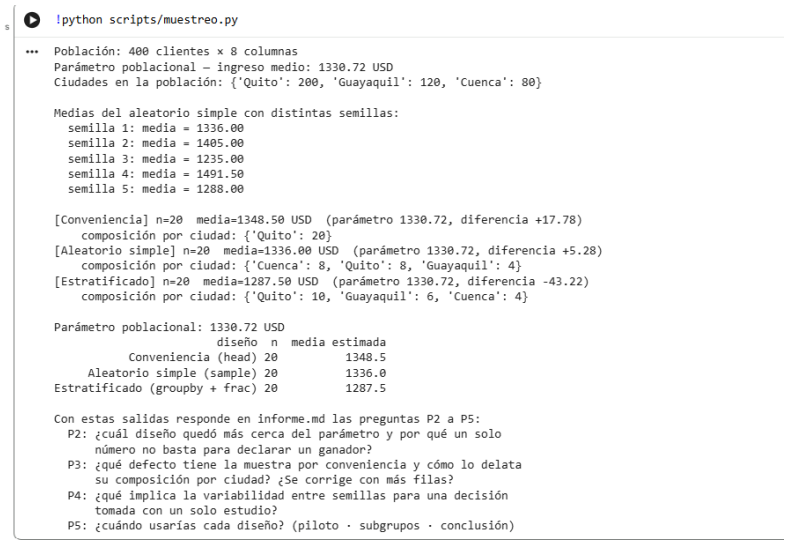
Python
```
poblacion = pd.read_csv("data/clientes_400.csv")
parametro = poblacion["ingresos_mensuales"].mean()      # 1330.72
muestra_conv = poblacion.head(20)                       # conveniencia
muestra_aas = poblacion.sample(20, random_state=1)      # aleatorio simple
muestra_est = poblacion.groupby("ciudad").sample(frac=0.05, random_state=1)  # estratificado
for semilla in [1, 2, 3, 4, 5]:                         # variabilidad entre semillas
    print(semilla, poblacion.sample(20, random_state=semilla)["ingresos_mensuales"].mean())
```

Concepto	Valor
Población (N)	400 clientes (Quito 200 / Guayaquil 120 / Cuenca 80)
Variable de interés	`ingresos_mensuales`
Parámetro poblacional (media)	1 330,72 USD
¿Por qué se muestrea si el parámetro existe?	Aquí pude calcularlo porque la base es pequeña y visible, y me sirvió de espejo para juzgar los diseños. En la práctica la población suele ser demasiado grande, costosa o inaccesible: el parámetro se desconoce y se estima con una muestra, por eso hay que saber si el diseño es confiable.

Diseño	n	Media estimada	Composición por ciudad	Diferencia vs. parámetro
Conveniencia (`head`)	20	1 348,50	Quito 20	+17,78
Aleatorio simple (`sample`, semilla 1)	20	1 336,00	Cuenca 8, Quito 8, Guayaquil 4	+5,28
Estratificado (`groupby` + 5 %)	20	1 287,50	Quito 10, Guayaquil 6, Cuenca 4	−43,22

Medias de 5 sorteos del aleatorio simple (semillas 1 a 5):

Semilla	1	2	3	4	5
Media	1 336,00	1 405,00	1 235,00	1 491,50	1 288,00
Diferencia vs. parámetro	+5,28	+74,28	−95,72	+160,78	−42,72



```
!python scripts/muestreo.py

Población: 400 clientes × 8 columnas
Parámetro poblacional — ingreso medio: 1330.72 USD
Ciudades en la población: {'Quito': 200, 'Guayaquil': 120, 'Cuenca': 80}

Medias del aleatorio simple con distintas semillas:
  semilla 1: media = 1336.00
  semilla 2: media = 1405.00
  semilla 3: media = 1235.00
  semilla 4: media = 1491.50
  semilla 5: media = 1288.00

[Conveniencia] n=20  media=1348.50 USD  (parámetro 1330.72, diferencia +17.78)
    composición por ciudad: {'Quito': 20}
[Aleatorio simple] n=20  media=1336.00 USD  (parámetro 1330.72, diferencia +5.28)
    composición por ciudad: {'Cuenca': 8, 'Quito': 8, 'Guayaquil': 4}
[Estratificado] n=20  media=1287.50 USD  (parámetro 1330.72, diferencia -43.22)
    composición por ciudad: {'Quito': 10, 'Guayaquil': 6, 'Cuenca': 4}

Parámetro poblacional: 1330.72 USD
                          diseño  n  media estimada
           Conveniencia (head) 20          1348.5
     Aleatorio simple (sample) 20          1336.0
Estratificado (groupby + frac) 20          1287.5

Con estas salidas responde en informe.md las preguntas P2 a P5:
  P2: ¿cuál diseño quedó más cerca del parámetro y por qué un solo
      número no basta para declarar un ganador?
  P3: ¿qué defecto tiene la muestra por conveniencia y cómo lo delata
      su composición por ciudad? ¿Se corrige con más filas?
  P4: ¿qué implica la variabilidad entre semillas para una decisión
      tomada con un solo estudio?
  P5: ¿cuándo usarías cada diseño? (piloto · subgrupos · conclusión)
```

Figura 4. Ejecución de muestreo.py: parámetro 1 330,72, medias por semilla, composición por ciudad y tabla comparativa.

P2. Parámetro y estimaciones. El parámetro vale 1 330,72 USD. Los diseños estimaron 1 348,50 (conveniencia), 1 336,00 (aleatorio simple) y 1 287,50 (estratificado). En esta corrida quedó más cerca el aleatorio simple (+5,28), pero eso no alcanza para declarar un ganador: una sola corrida mezcla el efecto del diseño con la suerte del sorteo. Con otra semilla el mismo aleatorio simple se alejó hasta +160,78, y el estratificado, el diseño más cuidadoso, quedó más lejos (−43,22).

P3. Defecto de la conveniencia. `head(20)` devolvió 20 clientes de Quito y ninguno de Guayaquil ni Cuenca, cuando Quito es solo la mitad de la población (200 de 400). La composición por ciudad lo delata: es un error sistemático (sesgo) porque el archivo viene ordenado por ciudad. No se corrige con más filas: tomar las primeras 100 seguiría sobrerrepresentando a Quito; más datos con el mismo diseño repiten el mismo defecto. Que su media (+17,78) haya quedado cerca fue coincidencia.

P4. Variabilidad entre semillas. Las cinco medias fueron 1 336,00; 1 405,00; 1 235,00; 1 491,50 y 1 288,00, un rango de 256,50 USD. Esa variación es error de azar (no sesgo) y existe, aunque el diseño sea correcto. Una empresa que decida con un solo estudio podría obtener cualquiera de esos valores, así que conviene informar un rango o repetir el muestreo, y no tratar una sola media como la verdad.

P5. Cuando usar cada diseño. Conveniencia: pilotos o pruebas rápidas, sin pretender generalizar. Estratificado: cuando los subgrupos deben aparecer sí o sí; aquí, las tres ciudades en su proporción real (10, 6 y 4). Aleatorio simple: cuando se quiere una conclusión sobre toda la población y no hay subgrupos críticos, aceptando que la composición varía de un sorteo a otro (en la semilla 1 salió 8, 8 y 4).

4. ¿Qué aprendí con esta práctica?

Ahora entiendo por qué el dtype no alcanza para clasificar una variable: `satisfaccion` llegó como `int64` y es ordinal, y `nivel_educacion` llegó como texto con un orden alfabético que no tiene sentido. También me quedó claro que un error de escritura al declarar categorías no avisa: el "Postgrado" con t dejó 2 faltantes sin ningún mensaje. Lo más difícil fue separar sesgo de variabilidad; lo resolví mirando la composición por ciudad de `head(20)` y comparando las cinco semillas. Además, Colab reinició la sesión y tuve que clonar de nuevo; aprendí a subir el commit apenas termino cada script. La próxima vez no sacaría conclusiones de una sola corrida.

5. Conclusiones

1. Las 8 columnas quedaron clasificadas con el criterio y verificadas en código: `edad` e `ingresos_mensuales` son continuas, `numero_hijos` es discreta, `genero` y `ciudad` son nominales, y `nivel_educacion` y `satisfaccion` son ordinales; el orden quedó declarado (mínimos Primaria y 2). Cumple los objetivos 1 y 2.
2. Con n = 20 en los tres diseños, las medias fueron 1 348,50, 1 336,00 y 1 287,50 frente al parámetro de 1 330,72. La conveniencia delató su sesgo (20 de 20 de Quito) y el estratificado garantizó la proporción 10, 6 y 4, mientras que el aleatorio simple dio 8, 8 y 4. Cumple el objetivo 3.
3. Las cinco semillas del aleatorio simple dieron entre 1 235,00 y 1 491,50 (rango de 256,50): una sola corrida no basta para decidir. La lección central es que el diseño decide, no el tamaño: más filas no corrigen un diseño sesgado. Cumple el objetivo 4.

Respuesta a la gerencia: no conviene estimar el ingreso promedio con los primeros registros de la base; se recomienda un muestreo estratificado por ciudad (porque garantiza que las tres ciudades aparezcan en su proporción real) y reportar el estimado junto con su variabilidad, no como un número único.

Alcance: con esta base de 400 clientes y una sola corrida por diseño, estos resultados no permiten declarar que un diseño sea mejor por su media en esta ocasión; solo muestran sus propiedades (sesgo, composición y variabilidad). No aplican a otras poblaciones.

6. Bibliografía

Suárez, C. (2026). *IDSD422-lab-muestreo-poblacion* [Repositorio del laboratorio y datos del caso]. GitHub. https://github.com/christian-suarez1979/IDSD422-lab-muestreo-poblacion

Declaración de uso de IA: Usé el asistente Claude (Anthropic) como apoyo para entender los pasos del laboratorio, depurar errores de ejecución. Ejecuté yo mismo todo el código en Colab, las capturas son de mi propia ejecución y revisé y puedo explicar cada parte de la entrega.